114 學年度 第一學期

數據科學專題

Term Project Final Report

第 12 組

313554049 陳靖燁

313554005 白宇辰

(編輯說明, 繳交時請刪除本段落:內文字體大小為12, 字型中文請使用標楷體, 英文數字請使用Times New Roman, 段落第一行空2字元。表格、圖表須有標題且置中, 表格標題在上、圖表標題在下。全文不限頁數。請注意, 下列所有章節缺一不可, 且分數與撰寫品質有關, 並非有寫即有分。)

1、 簡介（Introduction）

- 研究背景（Background）

在銀行業中，行銷活動（Marketing Campaigns）是推動金融商品銷售的重要手段，其中 定存（Term Deposit） 更是銀行取得穩定資金來源的關鍵產品。然而，傳統的電銷與行銷方式往往成本高、效率低，其 轉換率（Conversion Rate）通常偏低，導致大量資源被投入在無效客群上。

近年來，隨著資料科學在金融領域的應用逐漸成熟，Data-driven 行銷策略成為提升成效的必要手段。透過機器學習模型，銀行可以更精準地挑選潛在訂閱者，改善客戶分群與預測能力，不但能 降低行銷成本、提升投資報酬率（ROI），也能強化整體獲利能力。

因此，本研究旨在建構一套以資料為核心的預測模型，協助銀行在電銷定存推廣中做出更有效率的客戶篩選與決策。

- 研究動機（Motivation）

傳統銀行行銷方式多依賴大量外撥電話與廣泛式宣傳，但此類作法通常 效率低、成本高、訂閱率偏低，導致大量行銷資源被浪費在不具潛力的客群上。為提升行銷效益，銀行逐漸轉向 Data-driven 行銷策略，希望藉由資料分析與預測模型，改善客戶篩選準確度並提高投資報酬率（ROI）。

本研究希望透過比較多種機器學習模型，了解 accuracy 與 interpretability 之間的性能權衡（performance trade-off），從而找出兼具穩定度與可解釋性的模型。此外，我們亦著重於解釋性分析，如 SHAP，期望將模型揭露的關鍵特徵轉化為可行的行銷洞察，用於優化行銷策略、精準鎖定潛在客戶，並提升整體訂閱成功率。

- 研究目標（Research Aims）

本研究旨在針對銀行定存推廣活動建立一套具備高準確度與高可解釋性的預測框架，研究目標包括：

建構二元分類預測模型，判斷客戶是否會訂閱定存產品（Yes/No），以協助銀行提升行銷效率。

分析特徵重要性（Feature Importance），利用 SHAP 等方法提供可解釋的行銷洞察，協助理解客戶決策背後的關鍵因素。

比較多種機器學習演算法（如 Logistic Regression、Random Forest、Gradient Boosting、RNN 等），檢驗其效能差異與適用性。

確保模型具備良好的泛化能力，採用 stratified k-fold cross-validation 以避免偏差並提升結果穩定性。

與 Kaggle 競賽基準及相關研究進行對照，評估模型表現是否達到現有文獻與競賽基準的標準或有所提升。

- 挑戰與貢獻（Challenges and Contributions）

本研究在建立銀行定存訂閱預測模型的過程中，面臨以下兩項主要挑戰：

1. 類別不平衡問題（Class Imbalance Problem）

資料中正類別（訂閱 Yes）比例遠低於負類別（No），若未處理將使模型偏向預測多數類，導致少數類的召回率低落。

為減輕此偏差，本研究採用 SMOTE 等重採樣技術，且嚴格限制僅在 training set 中進行，以避免資料洩漏。同時，我們使用 AUROC、F1-score 等不受類別分布影響的指標來評估模型，確保在不平衡情境下仍能維持穩定且具辨識力的預測表現。

2. 過擬合風險與模型泛化能力（Overfitting Risk & Generalization）

複雜模型（如樹模型與深度學習架構）容易過度擬合訓練資料，導致測試階段表現不佳。

本研究採用 regularization、early stopping 等方法抑制過擬合，並透過 stratified k-fold cross-validation 檢驗模型在不同資料切分上的一致性。交叉驗證在此並非用來防止過擬合，而是用於 評估模型穩健性（robustness）與泛化能力（generalization consistency）。

2、 問題設定（Problem Setting）

- 問題描述（Problem Description）

Input（輸入）

模型的輸入包含來自銀行客戶與行銷活動的多種屬性資料，包括：

Demographics（人口統計資料）：年齡、職業、婚姻狀況、教育程度等

Financial Attributes（財務特徵）：帳戶餘額、貸款狀態、信用紀錄等

Campaign Information（行銷活動資訊）：聯繫方式、聯繫月份、前次活動結果、通話次數等

Process（處理流程）

Data Preprocessing（資料前處理）

進行資料清理、標準化（normalize）、處理缺失值。

Feature Engineering（特徵工程）

編碼類別型變數（categorical encoding），使其可用於機器學習模型。

Imbalance Handling（處理類別不平衡）

採用 SMOTE 或 class weighting，使模型更能識別少數類別（訂閱 Yes）。

Model Training（模型訓練）

建立多種預測模型，包括 Logistic Regression、Random Forest、CatBoost 等，並進行超參數調整。

Evaluation（模型評估）

使用 AUROC、F1-score、Precision、Recall 等指標評估模型在不平衡資料下的表現。

Interpretation（模型解釋）

使用 SHAP 與 feature importance 分析，提供特徵對預測影響的解釋性洞察。

Output（輸出）

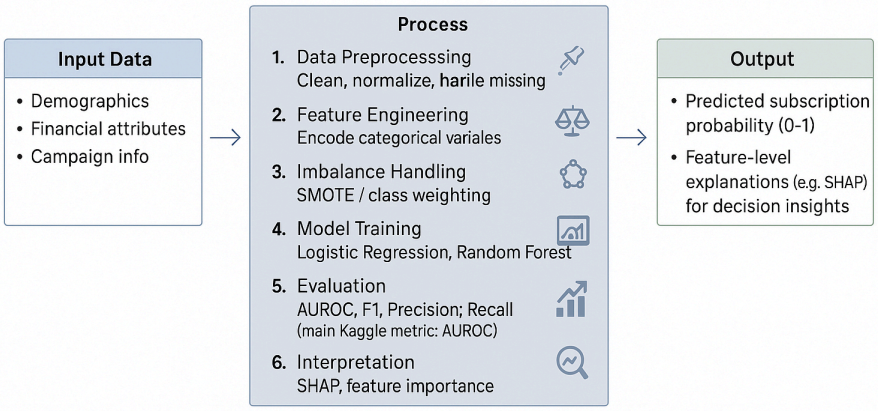
Predicted Subscription Probability（訂閱機率預測）

模型輸出每位客戶訂閱定存產品的機率（0–1）。

Feature-level Explanations（特徵層級的決策解釋）

提供 SHAP 等方法所產生的特徵貢獻度，協助銀行理解模型決策依據，並用於行銷策略制定。

- 需包含資料輸入（Input）/ 處理過程（Process）/ 輸出（Output）之圖表



- 利用一句敘述句，清楚說明此主題定義之研究問題。

本研究旨在建構並評估具可解釋性的機器學習模型，以預測銀行客戶是否會訂閱定存產品；透過解決類別不平衡問題並提升模型的解釋能力，本研究期望提供精準的客戶鎖定、降低行銷成本，並產生可行的行為與人口特徵洞察，以支援銀行在行銷決策上的優化。

This study aims to develop and evaluate interpretable machine learning models for predicting bank clients' subscription behavior.

By addressing class imbalance and enhancing model explainability, the project seeks to improve targeting accuracy, reduce marketing costs, and provide actionable insights into key behavioral and demographic factors influencing client decisions.

- 評估指標

本研究使用多項分類評估指標，以全面衡量模型在不平衡資料下的預測能力。各指標的說明如下：

Table: Evaluate Metric		
Metric（指標）	**Description**（描述）	**Purpose**（用途）
Accuracy	預測結果中，整體正確的比例。	作為整體表現的基準指標，但在類別不平衡時參考性有限。
Precision	模型預測為正類中，實際為正類的比例。	衡量模型控制 **false positives** 的能力。
Recall（**Sensitivity**）	實際正類中，被模型正確預測為正類的比例。	對於少數類（訂閱 Yes）特別重要，反映對正類的捕捉能力。
F1-score	Precision 與 Recall 的調和平均。	在類別不平衡情況下，提供更穩定的性能衡量。
AUROC	ROC 曲線下的面積。	Kaggle 主要評分指標，能在類別不平衡時提供更可靠的分類能力評估。

3、 方法設計（**Proposed Methods**）

本章節說明本研究從資料理解、資料前處理到模型建構的整體流程，並說明各步驟如何對應於前述兩項主要挑戰—— 類別不平衡問題與過擬合與泛化能力——以及研究貢獻中提到的 可解釋性分析與行銷洞察產出。

同時，也將回應在期末 QA 中常被提問的議題，例如季節性、交互特徵如何設計、SMOTE 與 5-fold 的角色等。

3.1 Data Understanding：資料理解與探索分析

本研究首先針對 Kaggle Playground S5E8 的銀行定存資料進行 EDA，以確立資料品質與特徵特性。根據 QA 報告中的分析（例如月份、duration、季節性行為等），我們獲得以下重要觀察：

資料品質檢查

- 確認所有欄位皆無缺失值，資料型態與欄位意義清楚。
- 將特徵依性質區分為 數值特徵（如 age、balance、duration、campaign、pdays、previous）與 類別特徵（如 job、marital、education、housing、loan、contact、month、poutcome 等）。

類別不平衡檢查（對應挑戰一：Class Imbalance）

- 計算目標變數 y 的分布，發現 訂閱 Yes 約佔 11%，No 約佔 89%，呈現高度不平衡。
- 初步比較只使用 accuracy 的 baseline，確認即使模型只預測「全部為 No」也能得到高 accuracy，證明 accuracy 不適合作為主要評估指標。

相關性與弱訊號分析（連結貢獻：找出關鍵特徵與季節性）

- 計算數值變數與 y 的相關係數，發現 duration 與訂閱率的相關性最強；有興趣的客戶通常會在電話中停留較久。

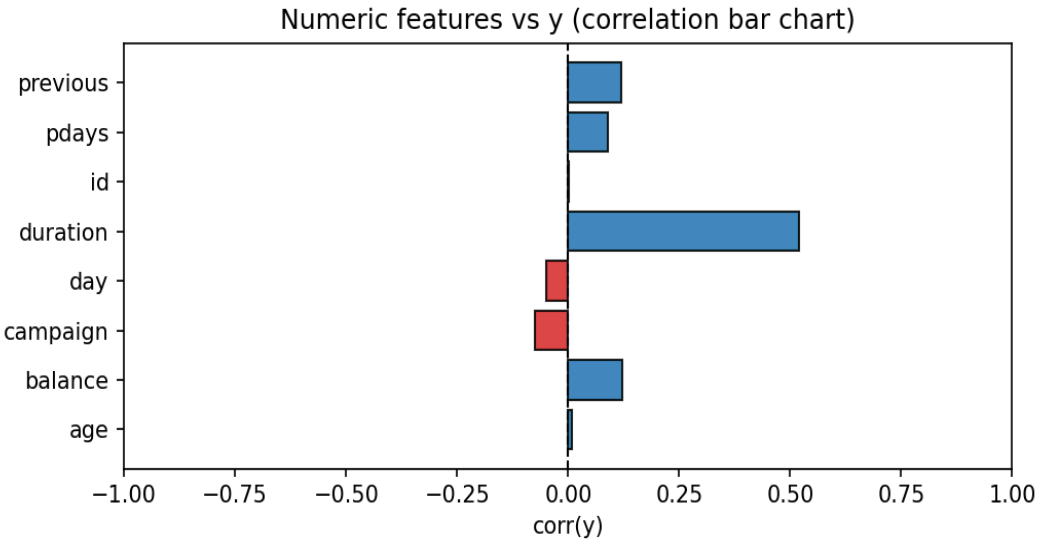


Fig: feature correclatrion to y

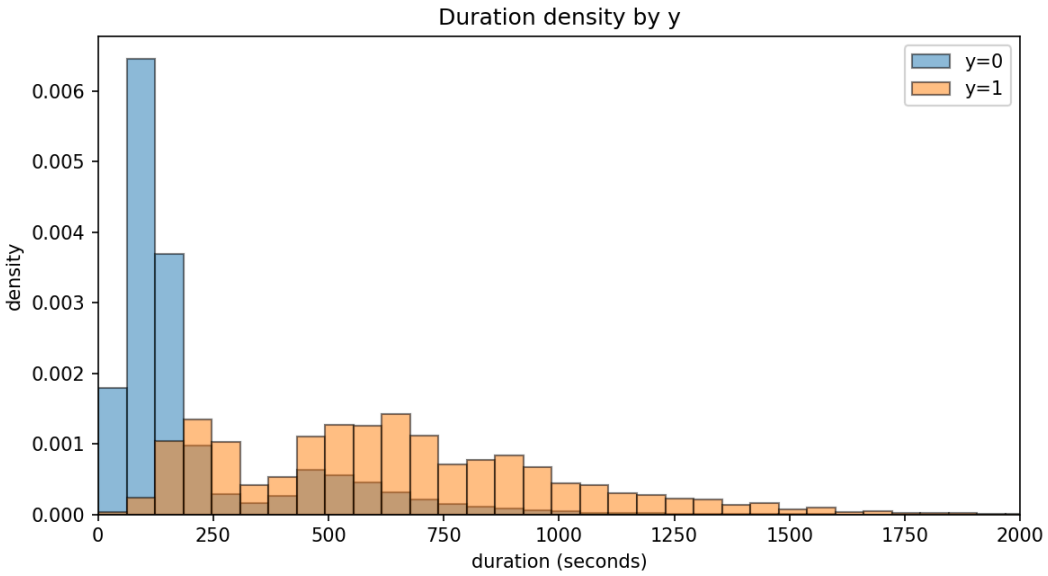


Fig: Duration density by y

- 針對 month、poutcome 等類別變數計算各類別對應的訂閱比例，觀察到
  - 在 3 月、9 月、10 月、12 月 訂閱比例較高，但整體樣本數較少。
  - 若前一次活動結果為 success，下一次訂閱機率顯著提升，但此類樣本同樣屬於少數。

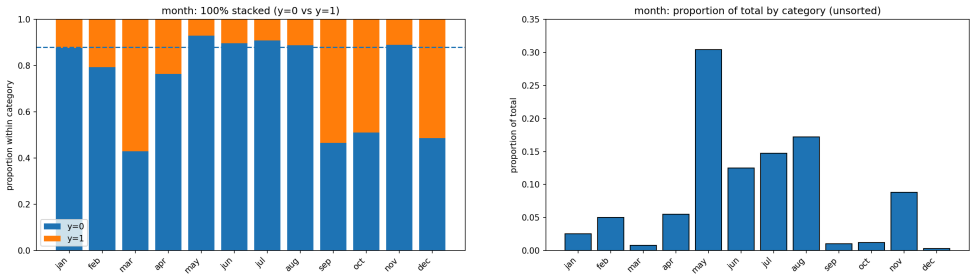


Fig: Subscription ratio by month

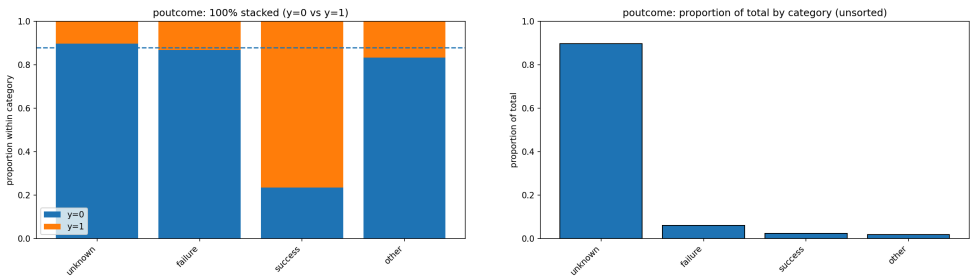


Fig: Subscription ratio by poutcome

- 這些結果暗示特徵之間存在 非線性與交互作用，難以僅用簡單線性模型捕捉。

透過上述步驟，我們確認了 資料乾淨、類別高度不平衡、且關鍵訊號分佈在少數特徵與少數樣本中，這直接形成後續方法設計的出發點。

3.2 Data Preparation：資料前處理與特徵工程

在資料前處理階段，我們設計了一系列處理流程，目標是同時解決類別不平衡與弱訊號／泛化性問題，並為後續的可解釋性分析打好基礎。

3.2.1 基礎前處理與型態轉換

型態標準化

- 將所有類別欄位轉換為 category 型態，以利後續 encoding 與記憶體管理。
- 避免模型做出錯誤的線性切割
- 強化後續 Target Encoding 的可解釋性
- 避免 overfitting 於類別 ID（對應挑戰二：提升泛化）

3.2.2 數值特徵轉換：Log、Sin/Cos、Scaling

- 交互特徵多使用 sin/cos + log 變換：
- (1) Log transform：平滑極端值（例如 balance）
- 避免模型在長尾分布的特徵上產生不穩定 decision boundary。
- (2) Sin/Cos transform：處理週期特徵（day、month、pdays）
- 避免把「1 月」與「12 月」視為距離極遠的數值。

3.2.3 類別特徵編碼：Target Encoding（TE）與 Count Encoding（CE）

- one-hot encoding 會造成維度爆炸，並因大量稀疏特徵導致過擬合。
- TE 將類別轉成「該類別平均訂閱率」→ 能從弱訊號中萃取統計意義。
- CE 則提供「該類別在資料中出現的代表性」。

TE 能減輕不平衡資料問題

例如「student 佔 1%，但 student 訂閱率可能高達 100%」→ TE 能放大此資訊，而不是被視為 noise。

避免資料洩漏（對應挑戰二：提升泛化）

TE 與 CE 僅在 training folds 內計算，validation/test 永不使用 label-derived 統計量。

3.2.4 交互特徵（Interaction Features）設計

四類交互特徵

1. 單變數非線性變換（sin/cos、log）
2. 數值×數值（numeric bigrams）
    - 如 age_x_balance、duration_x_campaign
3. 數值×類別（透過字串拼接）
    - 如 contact-month、duration-contact
4. 再經 TE / CE 處理後的高階組合
    - 如 TE_ORIG_balance-contact、TE_ORIG_day-month

設計原則

1. 先把可能有意義的 candidate 顯式構造出來
2. 再由 model / SHAP / CV 來篩選
3. 用 regularization 控制過擬合

→ 對應挑戰二：弱訊號 → 需更多特徵互動以提升泛化

3.2.5 類別不平衡處理：SMOTE（僅用在 Training Set）

如果訓練資料正類太少，模型會「記住少數樣本」而造成隱性過擬合。

SMOTE 能讓 decision boundary 更平滑，不會聚焦在少數正樣本的噪音上。

只用在 Training Set

- validation/test 不做 SMOTE → 避免資料洩漏
- 保持現實的正負類比例，評估才可信

SMOTE 不會直接防止 overfitting，但它能：

- 減少少數類樣本不足造成的 decision boundary 過度集中
- 與 5-fold CV 搭配，可以檢查「是否因資料切分不同而產生極端 variance」

3.3 Data Modeling（模型建構）

本研究採用三種模型族群，並搭配早停、正規化、CV 與 SHAP 分析，對應挑戰二與貢獻。

3.3.1 三類模型架構

(1) AdaBoost（Baseline）

傳統 boosting，弱學習器由淺層樹構成

目的：提供最基本的 performance floor

(2) RNN（SOTA 模型）

將經 embedding 後的 tabular 特徵視為序列

能捕捉特徵之間的相對順序與高維交互

若弱訊號為主，RNN 可疊加更多 weak interactions 獲得更好表現

(3) LightGBM（主力模型）

使用 leaf-wise growth、histogram-based split

調參包含：learning rate、num_leaves、feature_fraction、bagging_fraction

3.3.2 Early Stopping 與 Regularization（對應挑戰二：避免過擬合）

所有模型均採用 early stopping：

- LightGBM：透過 validation loss 監控
- RNN：dropout + L2 regularization
- AdaBoost：限制最大樹深與 estimator 數量

此外，TE/CE、交互特徵、數值轉換也間接幫助提升泛化。

3.3.3 5-Fold Stratified Cross-Validation（CV）

而是用來檢查穩定性（QA 問題 3 的澄清）

CV 主要作用：

- 確保模型不依賴特定資料切分
- 若 5 個 fold 表現一致 → 模型具有泛化一致性
- 保留原始不平衡比例 → 評估更接近真實部署情境

這是本研究處理泛化能力的核心方法之一。

3.3.4 SHAP 可解釋性分析（對應貢獻：行銷洞察）

- duration、balance 成為最重要特徵
- month 存在季節性
- job、marital、education 等靜態人口資訊影響極低
- 可根據 SHAP 高分段來決定實際行銷策略，例如優先撥打高 balance 客戶

4、 實驗設定（**Experimental Setting**）

本章節將說明本研究所使用的資料集來源、資料特性與檢核表、Baseline 與 SOTA 模型、評估策略，以及模型訓練所使用的實驗環境。

4.1 資料集相關描述（Dataset Description）

本研究採用之資料集為 Kaggle Playground 系列競賽 “Playground Series – Season 5 Episode 8” 所提供的銀行定存訂閱資料集，為經由深度生成模型所合成（synthetic）的 UCI Bank Marketing 擴充版本。此資料集包含客戶屬性、財務行為、與行銷活動互動紀錄，用於預測客戶是否會訂閱定存產品（Yes/No）。

資料來源：

https://www.kaggle.com/competitions/playground-series-s5e8/overview

資料筆數：

- 訓練資料（train）：750,000 筆
- 測試資料（test）：250,000 筆（無標記，用於 Kaggle leaderboard）
- 總筆數：1,000,000

資料欄位型態如下：

Table: Dataset attributes

Variable	Description	Type / Values
age	Client’s age	Numeric
balance	Average yearly balance (EUR)	Numeric
day	Last contact day of month	Numeric (1–31)
duration	Last contact duration (seconds)	Numeric
campaign	Number of contacts in this campaign	Numeric
pdays	Days since last contact (-1 = never contacted)	Numeric
previous	Number of contacts before this campaign	Numeric
y	Subscribed to term deposit? (target)	Binary: yes, no
job	Type of job	Categorical: admin., blue-collar, entrepreneur, etc.
marital	Marital status	Categorical: married, single, divorced
education	Education level	Categorical: primary, secondary, tertiary, unknown

default	Has credit in default?	Categorical: yes, no
housing	Has a housing loan?	Categorical: yes, no
loan	Has a personal loan?	Categorical: yes, no
contact	Contact communication type	Categorical: unknown, telephone, cellular
month	Last contact month	Categorical: jan, feb, …, dec
poutcome	Outcome of previous campaign	Categorical: unknown, other, failure, success

資料特性摘要

- 無缺失值，資料乾淨。
- 目標呈現高度不平衡（Yes 約 11%，No 約 89%）。
- duration 與 y 的相關性最強，多數其他特徵屬於弱訊號但存在非線性關係。
- 月份（March、September、October、December）呈現較高成功率，具季節性特徵。

資料集檢核表

Domain:

☑ Finance & Economics

Source:

☑ Public Kaggle competition (leaderboard & baselines available)

Size:

☑ 1M samples (≫ 5k minimum)

Features:

☑ Clear semantics (age, job, contact, etc.) → interpretable

Task:

☑ Binary classification (Yes/No subscription)

4.2 Baseline Models 與 SOTA 模型

為比較不同模型架構在銀行定存預測任務中的效果，本研究選擇兩種代表性模型作為 Baseline 與 SOTA：

(1) AdaBoost（Baseline）

- 經典 boosting ensemble 方法
- 具可解釋性、計算量低，但對高維特徵與不平衡資料較不敏感
- 作為本研究的弱基準（weak baseline）

(2) RNN（SOTA 方法）

- 參考近年研究中「將 tabular reshaping 成序列」的深度模型方法
- 能學習特徵間的順序依賴與高維交互作用
- 在本研究中展現優異召回能力

4.3 評估策略（Evaluation Strategy）

(1) Stratified K-Fold Cross Validation

本研究採用 Stratified 5-Fold, 原因如下:

- 保留各折中正負類比例, 避免偏差
- 提升模型穩健性（robustness）
- 評估泛化能力（generalization consistency）

(2) 不使用 Accuracy 作為主要評估指標

因類別不平衡嚴重, Accuracy 不具參考性。

(3) 主要評估指標:

- F1-score（正負均衡性能）
- ROC-AUC（整體分類能力）
- PR-AUC（AP）（不平衡資料最重要指標）
- Precision / Recall
- 最佳 Threshold（對銀行行銷決策極具價值）

(4) 嚴格避免資料洩漏

- Target Encoding、SMOTE 一律只在 training folds 內擬合
- 測試資料不允許出現任何 label-derived 統計量

此策略確保模型評估結果的真實性。

4.4 實驗環境（Environment）

本研究使用之環境如下:

(1) 作業系統（OS）

- Windows / Linux 皆有使用

(2) 開發工具與語言

- Python 3
- VSCode

(3) 主要套件與框架

- pandas、numpy
- scikit-learn
- LightGBM
- TensorFlow / Keras（用於 RNN）

此環境能支援大規模資料、Boosting 模型訓練, 以及深度學習模型架構。

5、 實驗結果（**Experimental Results**）

本節將依序呈現各模型的 ROC 曲線、PR 曲線、最佳化 F1 閾值分析、SHAP 特徵解釋結果，並比較三種模型（AdaBoost、RNN、LightGBM）的整體效能。此外，我們亦進行「移除 duration 特徵」的真實場景模擬，以評估在缺乏電銷通話資訊時模型的穩健性與實際策略意涵。

5.1 ROC Curve 比較

在 ROC 曲線中，LightGBM 的整體判別能力最佳，其 AUC 達 0.9750，明顯優於 RNN（0.9667）與 AdaBoost（0.9446）。

此結果顯示 LightGBM 能有效處理非線性特徵互動，並在資料不平衡的情況下仍維持穩定表現。

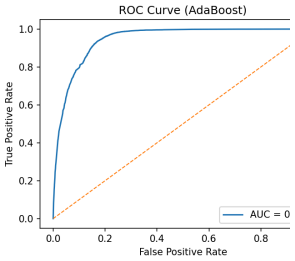


Fig: AdaBoost ROC curve

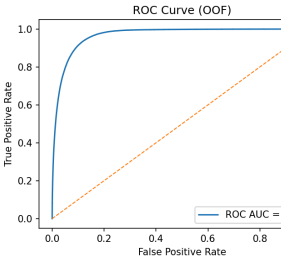


Fig: RNN ROC curve

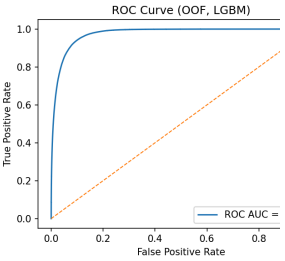


Fig: LGBM ROC curve

5.2 Precision–Recall Curve 比較

PR 曲線在類別不平衡場景中特別重要。LightGBM 同樣展現最高 AP（PR-AUC = 0.8483），RNN 緊追在後（0.8025），AdaBoost 則最低（0.6769）。
此結果說明：

- LightGBM 在少數類（訂閱 Yes）上的召回能力與 precision 兼具，是整體最適用於銀行行銷預測的模型。

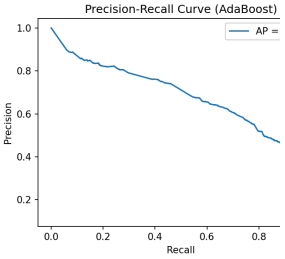


Fig: AdaBoost PR curve

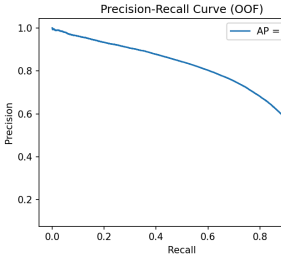


Fig: RNN PR curve

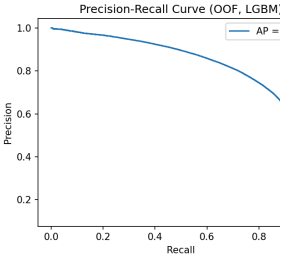


Fig: LGBM PR curve

5.3 最佳化 F1 Score 與 Threshold 分析

不同模型的預測輸出需要搭配適當閾值以取得最佳 F1-score。
根據實驗結果，三模型的最佳 F1-score 如下：

Table: Model performance compare				
Model	**F1-opt**	**Threshold**	**Precision**	**Recall**
AdaBoost	0.6517	0.421	0.5832	0.7384
RNN	0.7365	0.331	0.6888	0.7912
LightGBM	**0.7721**	0.368	**0.7345**	**0.8137**

LightGBM 在 precision 與 recall 之間取得最佳平衡，達到最高 F1 分數。

此分析對銀行實務具有重要價值：
若行銷資源有限，可利用最佳 threshold 進行客戶排序，以同時提升召回率（減少錯過潛在客戶）與 precision（避免浪費電話行銷成本）。

5.4 SHAP 特徵重要性分析

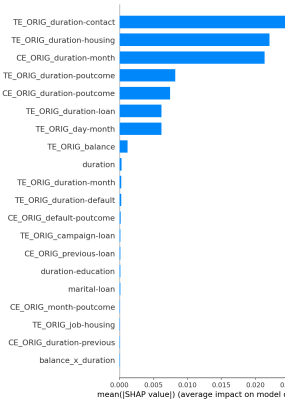


Fig: AdaBoost SHAP bar

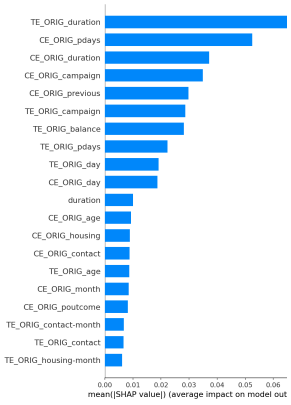


Fig: RNN SHAP bar

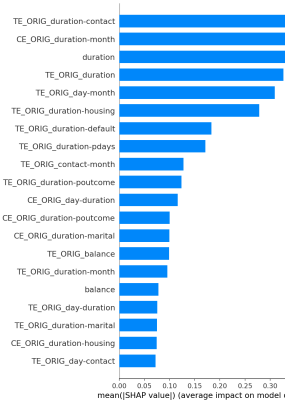


Fig: LGBM SHAP bar

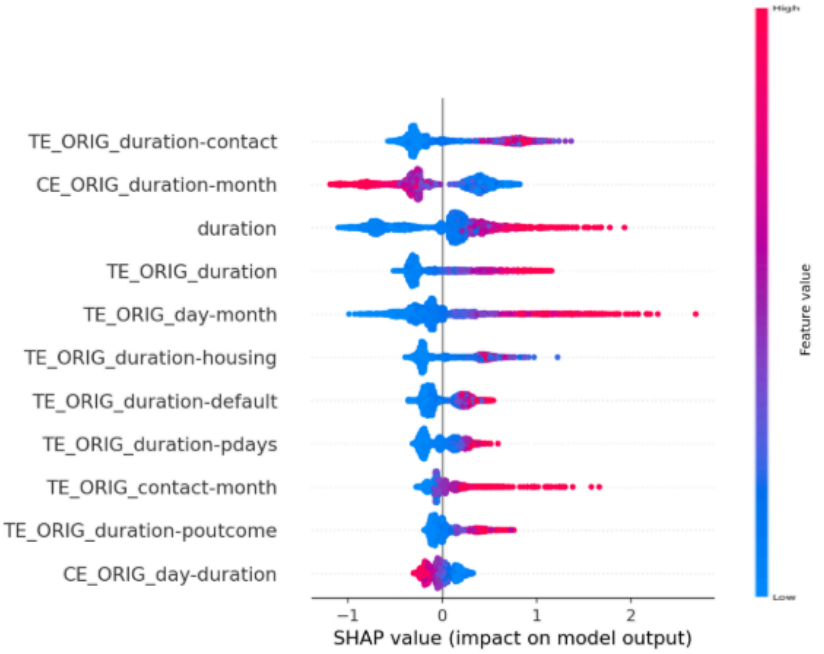


Fig: LGBM SHAP summary

(1) duration 是三模型共同的最強預測因子

- 高通話時長明顯提升訂閱機率。
- 這反映真實電銷流程：有興趣的客戶通常會願意停下來聆聽與對話。

(2) 經濟能力與行為特徵（如 balance, pdays）在無 duration 時成為主力訊號

SHAP 結果顯示：

- balance 在無 duration 模型中躍升為第一重要特徵（PDF 第 10 頁）
- 表示客戶的財務深度是判斷訂閱意願的重要前置訊號。

(3) 一般人口統計特徵（job、marital、education）皆影響甚低

與銀行常見的直覺不同，模型結果指出：

以職業或婚姻狀態作為客群篩選基準並不有效，容易造成行銷資源浪費。

5.5 Encoding Ablation Study：移除 Target / Count Encoding 的性能影響分析

在前述實驗中，我們採用了 Target Encoding (TE) 與 Count Encoding (CE) 來強化類別型特徵的表現。然而，為了驗證這兩項資料前處理是否對模型性能具有實質貢獻，我們進一步進行了「移除 TE / CE 後」的 ablation study，並以 LightGBM 重新評估其 ROC 曲線、PR 曲線與 SHAP 特徵重要性。

Table: Model without encoding performance

Metric	Original	Without Encoding	Diff
F1 Score	0.7721	0.7610	↓ 27%
Threshold	0.368	0.3778	↓ 0.1
ROC-AUC	0.9750	0.9723	↓ 0.19
AP (PR-AUC)	0.8483	0.8348	↓ 0.3

移除 Target Encoding 與 Count Encoding 後，模型性能僅出現輕微下降：

F1-score 減少 0.0111，ROC-AUC 減少 0.0027，PR-AUC 減少 0.0135，整體差異相當有限。這顯示在我們的資料設定中，TE/CE 能帶來些微但穩定的效能提升，但不像 duration 這類高影響特徵般對模型造成劇烈影響。換言之，編碼方法屬於增強效果（enhancement），但非性能核心依賴項。

5.6 真實場景實驗：移除 duration（No-Duration Scenario）

為模擬「尚未撥打電話前」的預測情境，我們重新訓練了不含 duration 特徵的 LightGBM 模型。

Table: Model without duration performance

Metric	Original	**Without Duration**	Diff
F1 Score	0.7721	**0.5641**	↓ 27%
Threshold	0.368	**0.268**	↓ 0.1
ROC-AUC	0.9750	**0.7844**	↓ 0.19
AP (PR-AUC)	0.8483	**0.5404**	↓ 0.3

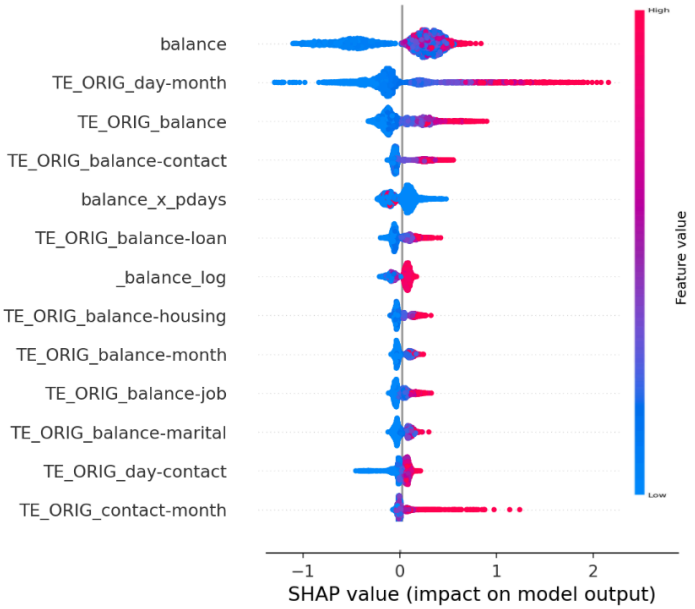


Fig: Without duration SHAP summary

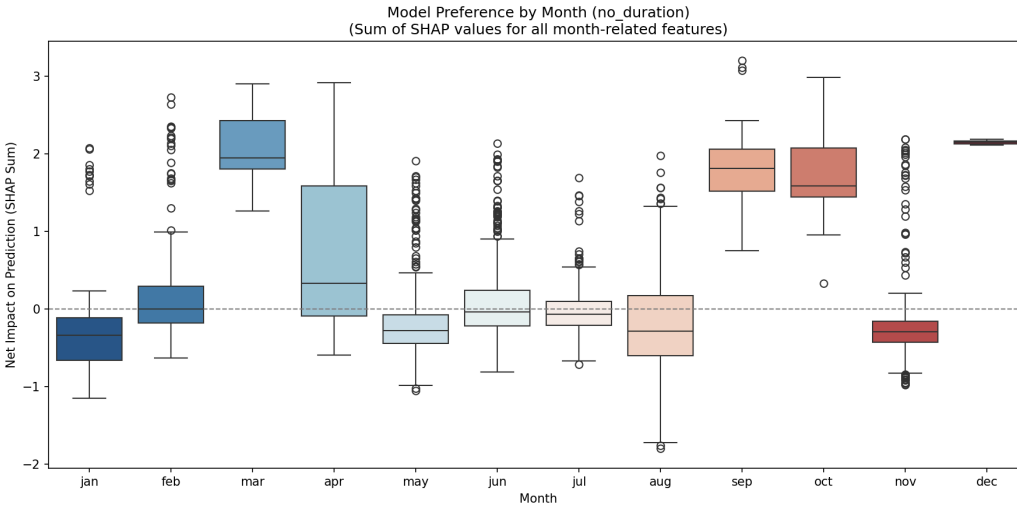


Fig: Model preference by month

主要發現:

(1) 模型嚴重依賴通話資訊, 移除後性能下降明顯(F1 -27%)

證明 duration 是高度資訊性的行為特徵。

(2) Balance 成為最佳前置預測因子

在電話撥出前, 銀行可依「客戶平均餘額」排序名單, 提高轉換率。

(3) 月份資訊呈現季節性偏好模式

- 3 月、9 月、10 月、12 月 的訂閱意願顯著較高。
  這可作為銀行規劃行銷檔期的重要參考。

5.7 綜合洞察（Insights）

低影響特徵（可忽略於行銷名單篩選）：

- 人口統計：job、marital、education
- 一般貸款狀態：housing、loan

→ 不適合作為行銷名單的初步篩選條件。

高價值特徵（應優先納入行銷策略）：

- 財務流量（如 balance、pdays）
- 與定存相關之數位行為（如瀏覽定存頁面，可視為未來延伸方向）
- 詳細拒絕原因碼（若銀行內部有相關紀錄）

5.8 實驗結果小結

綜整所有實驗發現：

1. LightGBM 整體最佳，兼具高效能與解釋性。
2. duration 是電銷場景的關鍵訊號，移除後性能大幅下降。
3. 若無通話資訊，balance 成為最強前置預測因子。
4. 月份呈現季節性成功機率，可形成實務行銷策略（如集中於 3/9/10/12 月）。
5. 人口特徵對預測影響低，應避免作為過度簡化的行銷準則。

6、 總結與限制（Conclusion and Limitation）

- 總結過程遇到的難題, 以及對應之解決方法。
- 總結研究成果(包含實驗分析、洞見分析、研究貢獻等)。
- 描述此研究的限制(Limitation), 以及未來發展(Future Works)。

7、 參考文獻 (Reference)

8、 組員分工與各自執行細項 (Work Distribution Chart)